

線形代数

行列式

$$\begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc$$
$$\begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = a_{11} \begin{vmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{vmatrix} - a_{12} \begin{vmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{vmatrix} + a_{13} \begin{vmatrix} a_{21} & a_{22} \\ a_{31} & a_{32} \end{vmatrix}$$

固有値、固有ベクトル

- ある行列Aに対してベクトルxと係数λがある
- このλを固有ベクトル、固有値という

$$A\vec{x} = \lambda\vec{x}$$
$$\begin{vmatrix} a_{11} - \lambda & a_{12} \\ a_{21} & a_{22} - \lambda \end{vmatrix} = 0$$

固有値分解

- 行列の累乗の計算を容易にするため
- ある正方形の行列を、固有ベクトルを並べた行列と固有値を対角線上に並べた行列（対角線以外は0にして固有値を表現）で構成される式に表現しなおす

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & \dots \\ 0 & \lambda_2 & \dots \\ \dots & \dots & \dots \end{pmatrix}$$
$$V = (\vec{v}_1 \quad \vec{v}_2 \quad \dots)$$
$$AV = V\Lambda \text{ より}$$
$$A = V\Lambda V^{-1}$$

特異値分解

- 正方形以外の行列を疑似的に固有値分解すること
- 対象の行列を転置させ、転置前の行列と転置後の行列の積で正方形化する。それを固有値分解

$$MV = US \quad M^T U = VS^T$$
$$M = USV^{-1} \quad M^T = VS^T U^{-1}$$
$$MM^T = USV^{-1}VS^T U^{-1} = USS^T U^{-1}$$

- よって左特異ベクトルと特異値の二乗が求められる

- データを減らすとき、単純にデータを減らしていくと、元の画像と異なる画像になる
- 特異値を減らすことで、元の画像が分かるまま、データを減らすことが可能

確率・統計

頻度確率(客観確率)

- 発生する頻度

ベイズ確率(主観確率)

- 信念の度合い

条件付き確率

- ある事象 $X=x$ が与えられた下で、 $Y=y$ となる確率

$$P(Y = y|X = x) = \frac{P(Y = y, X = x)}{P(X = x)}$$

独立な事象の同時確率

- お互い因果関係のない事象 X, Y が同時に発生する確率

$$P(X, Y) = P(X)P(Y) = P(Y, X)$$

ベイズ則

$$P(X|Y)P(Y) = P(Y|X)P(X)$$

期待値

- P は確率、 f は確率変数

$$\text{期待値 } E(f) = \sum_{k=1}^n P(x_k) f(x_k)$$

- 連続する値の場合

$$\text{期待値 } E(f) = \int P(x) f(x) dx$$

分散

- データの散らばり具合
- データの格々の値が期待値からどれだけずれているか平均したもの

$$\text{分散} Var(f) = E((f(x) - E(f))^2) = E(f(x)^2) - E(f)^2$$

共分散

- 2つのデータ系統の傾向のちがい
- 正(負)の値を取れば似た(逆の)傾向
- ゼロを取れば関係性にと乏しい

$$\begin{aligned}\text{共分散} Var(f) &= E((f(x) - E(f))(g(Y) - E(g))) \\ &= E(fg) - E(f)E(g)\end{aligned}$$

ベルヌーイ分布

- コイントスのイメージ
- 裏と表で出る割合が等しくなくとも扱える

$$P(x|\mu) = \mu^x(1 - \mu)^{1-x}$$

マルチヌーイ(カテゴリカル)分布

- サイコロを転がすイメージ
- 各面の出る割合が等しくなくとも扱える

二項分布

- ベルヌーイ分布の多試行版

$$P(x|\lambda, n) = \frac{n!}{x!(n-x)!} \lambda^x (1-\lambda)^{n-x}$$

ガウス分布

- 釣鐘型の連続分布

$$N(x; \mu, \sigma^2) = \sqrt{\frac{1}{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right)$$

情報理論

自己情報量

- 対数の底が2のとき、単位はビット(bit)
- 対数の底がネイピアのeのとき、単位は(nat)
- 情報量→珍しいほど価値がある
- ある事象が起きた時に、どのくらいその事象が起こりにくいか

- 確率が低いほど、情報量が多い

$$I(x) = -\log(P(x)) = \log(W(x))$$

$$W(x) = \frac{1}{P(x)}$$

シェノンエントロピー

- 自己情報量の期待値

$$H(x) = E(I(x))$$

$$= -E(\log(P(x)))$$

$$= -\sum(P(x)\log(P(x)))$$

カルバック・ライブラー ダイバージェンス

- 同じ事象・確率変数における異なる確率分布P,Qの違いを表す

$$D_{kl}(P||Q) = E_{x \sim P} \left[\log \frac{P(x)}{Q(x)} \right]$$

$$= E_{x \sim P} [\log P(x) - \log Q(x)]$$

交差エントロピー

- KLダイバージェンスの一部分を取り出したもの
- Qについての自己情報量をPの分布で平均している

$$H(P, Q) = H(P) + D_{kl}(P||Q)$$

$$H(P, Q) = -E_{x \sim P} \log Q(x)$$

$$= -\sum P(x) \log(P(x))$$